

Guide Onboarding – Consultant Data

Sommaire

Introduction

1. Horaires de travail
2. Outils utilisés dans l'équipe Data
3. Accès et sécurité
4. Gestion de projet
5. Workflow Git
6. Pipeline RAG interne
7. Bonnes pratiques Data
8. Processus d'intégration
9. Support technique
10. Conclusion

Guide Onboarding – Consultant Data

Introduction

Bienvenue dans l'équipe Data & Analytics.

Ce guide a pour objectif de faciliter votre intégration au sein de l'entreprise et de vous présenter les outils, processus et bonnes pratiques utilisés dans les projets Data.

Le consultant Data participe à plusieurs missions liées à :

- l'analyse de données,
 - la création de dashboards,
 - le développement de pipelines de données,
 - l'intelligence artificielle,
 - le machine learning,
 - les systèmes RAG et LLM.
-

1. Horaires de travail

Les horaires standards sont :

- Début : 9h00
- Pause déjeuner : 12h30 à 13h30
- Fin : 18h00

Les consultants doivent être connectés avant le daily meeting du matin.

Le télétravail est autorisé uniquement après validation du manager.

2. Outils utilisés dans l'équipe Data

L'équipe Data utilise principalement les technologies suivantes :

Langages

- Python
- SQL
- JavaScript

Bases de données

- PostgreSQL
- MongoDB

Outils Data Engineering

- Apache Airflow
- Docker
- GitLab CI/CD

Intelligence Artificielle

- LangChain
- Haystack
- Ollama
- Hugging Face Transformers

Visualisation

- Power BI
 - Tableau
-

3. Accès et sécurité

Chaque employé reçoit :

- une adresse email professionnelle,
- un compte GitLab,
- un accès VPN,
- un compte Jira.

Le VPN est obligatoire pour accéder aux ressources internes à distance.

Les mots de passe doivent contenir :

- au moins 12 caractères,
- une lettre majuscule,
- un chiffre,
- un caractère spécial.

Il est interdit de partager ses identifiants avec une autre personne.

4. Gestion de projet

Les projets sont organisés avec la méthode Agile Scrum.

Les réunions importantes sont :

Daily Meeting

Horaire : 9h15

Durée : 15 minutes

Chaque membre doit expliquer :

- ce qu'il a réalisé,
- les blocages rencontrés,
- les tâches prévues.

Sprint Planning

Organisé chaque début de sprint.

Sprint Review

Présentation des fonctionnalités développées.

5. Workflow Git

Chaque développeur doit :

1. créer une branche dédiée,
2. développer la fonctionnalité,
3. faire un commit clair,
4. ouvrir une Merge Request.

Exemple de nom de branche :

```
feature/add-rag-pipeline
```

Exemple de commit :

```
git commit -m "Add embedding pipeline"
```

6. Pipeline RAG interne

Le système RAG interne permet aux employés de poser des questions sur :

- les procédures RH,
- les guides techniques,
- les documentations projets,

- les politiques internes.

Architecture utilisée :

1. Import des documents PDF
2. Découpage en chunks
3. Création des embeddings
4. Stockage dans PostgreSQL pgvector
5. Recherche vectorielle
6. Génération de réponse avec un LLM

Les modèles utilisés sont :

- multilingual-e5-small
 - Gemma 2B
 - Mistral 7B
-

7. Bonnes pratiques Data

Les règles importantes sont :

- écrire du code lisible,
- documenter les pipelines,
- éviter le hardcoding,
- utiliser des variables d'environnement,
- versionner le code avec Git.

Les notebooks Jupyter ne doivent pas contenir de mots de passe.

8. Processus d'intégration

Durant la première semaine, le consultant doit :

- installer les outils nécessaires,
- configurer Docker,
- accéder au VPN,
- cloner les repositories Git,
- lire la documentation interne.

Durant le premier mois :

- participation à un mini projet,
 - formation LangChain,
 - découverte des pipelines RAG,
 - initiation aux embeddings.
-

9. Support technique

En cas de problème :

Support IT

Email : support-it@entreprise.com

Équipe Data

Email : data-team@entreprise.com

Ressources utiles

- Documentation interne
 - Wiki projet
 - Guides DevOps
 - Base de connaissances RAG
-

10. Conclusion

Le consultant Data joue un rôle important dans les projets d'intelligence artificielle et d'analyse de données.

L'objectif principal est de :

- produire des solutions fiables,
- automatiser les traitements,
- améliorer la qualité des données,
- développer des systèmes intelligents.

Bienvenue dans l'équipe Data & Analytics.